Prise de décision par imagination visuelle

Réarrangement autonome d'objets par un robot à l'aide de modèles de fondation

Encadrant : Nathan Crombez

Travail de référence : DALL-E-Bot : Introducing Web-Scale Diffusion Models to Robotics (arXiv:2210.02438)

1. Introduction et objectif du rapport

Ce sujet propose d'exploiter des modèles de fondation (vision, langage, génération d'image, action) pour permettre à un robot de réarranger des objets de manière autonome, sans apprentissage supplémentaire (« zero-shot »). Le principe général tient en trois temps : le robot observe une scène et la décrit en langage naturel, il génère ensuite une image représentant un agencement « naturel » et humain de ces mêmes objets, puis il reproduit physiquement cette organisation par une série de manipulations (pick-and-place).

Ce rapport a un double objectif. D'une part, expliquer en détail le pipeline du travail de référence cité dans le sujet (DALL-E-Bot, 2022) et le décomposer en briques technologiques indépendantes. D'autre part, et c'est le cœur du travail demandé, identifier pour chaque brique les modèles plus récents (2024-2026) qui pourraient remplacer ceux utilisés en 2022, ainsi que les architectures alternatives publiées depuis, qui changent parfois la logique même du pipeline plutôt que seulement les modèles individuels.

Une clarification de vocabulaire utile : le sujet indique 2023, mais l'article DALL-E-Bot a en réalité été mis en ligne sur arXiv fin 2022 (octobre 2022) et publié dans la revue IEEE Robotics and Automation Letters en 2023. Les deux dates sont donc correctes selon qu'on parle de la prépublication ou de la publication officielle.

2. Le travail existant : DALL-E-Bot

2.1 Principe général

DALL-E-Bot (Kapelyukh, Vosylius et Johns, Imperial College London / Dyson Robotics Lab) est le premier travail à utiliser un modèle de diffusion image entraîné à l'échelle du Web (DALL-E 2) comme « moteur d'imagination » pour un robot. L'idée centrale est que les préférences humaines en matière d'agencement d'objets sont implicitement présentes dans les milliards d'images de scènes réelles disponibles sur Internet, sur lesquelles ces modèles ont été entraînés. Plutôt que de collecter un jeu de données d'exemples d'arrangements « désirables » (approche classique et coûteuse), le robot interroge directement ce savoir déjà encodé dans le modèle de diffusion.

Le système revendique trois propriétés clés : il est zero-shot (aucune démonstration ni entraînement propre à la tâche), open-set (aucune liste fermée d'objets ou de scènes prédéfinie, grâce au pré-entraînement à l'échelle du Web) et autonome (aucune spécification de but fournie par un humain).

2.2 Le pipeline détaillé, étape par étape

Le pipeline est modulaire et s'enchaîne comme suit :

- Observation : une caméra RGB-D montée sur le poignet du robot capture une image de la scène initiale, vue de dessus (tabletop).
- Représentation par objet : chaque objet est détecté et segmenté, puis décrit par un triplet (masque de segmentation, légende textuelle, vecteur de caractéristiques visuo-sémantiques).

- Construction du prompt textuel : les légendes sont réduites à leurs seuls noms communs (extraction de noms via étiquetage grammatical), puis assemblées en une phrase du type « A fork, a knife, a plate, and a spoon, top-down ».
- Génération de l'image cible : le prompt est envoyé à DALL-E 2, qui génère un lot d'images candidates représentant un agencement humain plausible des mêmes objets. Des masques d'image (inpainting) permettent d'empêcher le modèle de déplacer certains objets fixes, de contraindre les bords de la table, et de supprimer les ombres qui biaiseraient la génération.
- Sélection et filtrage : les images générées qui n'ont pas le bon nombre d'objets ou qui présentent des chevauchements sont écartées (stratégie « sample-and-filter », jugée cruciale par les auteurs).
- Appariement objet à objet : chaque objet réel est associé à l'objet correspondant dans l'image générée par similarité cosinus de leurs vecteurs CLIP, l'appariement optimal étant calculé par l'algorithme hongrois (Hungarian Matching).
- Estimation de pose : les masques de segmentation des objets appariés sont alignés par ICP (Iterative Closest Point) pour obtenir une transformation 2D (x, y, θ). Pour les objets quasi symétriques (un couteau, par exemple), l'ambiguïté à 180° est levée en comparant des cartes de caractéristiques sémantiques issues d'un réseau ImageNet.
- Passage en 3D et exécution : la caméra de profondeur permet de projeter ces poses dans l'espace cartésien réel, et un bras Franka Emika Panda équipé d'une ventouse exécute une séquence de saisies et déposes, en écartant temporairement les objets qui entreraient en collision.

2.3 Les modèles utilisés en 2022

Brique	Modèle(s) utilisé(s)	Rôle
Détection & segmentation	Mask R-CNN (Detectron2, entraîné sur LVIS, 1200 classes)	Localiser chaque objet et produire son masque de segmentation
Description textuelle (captioning)	OFA (image captioning)	Générer une légende de chaque objet, plus fiable que l classes prédites par Mask R-CNN
Extraction de noms	Étiquetage grammatical (POS tagging) via la librairie Flair NLP	Extraire le nom commun de chaque légende pour construire le prompt
Caractéristiques sémantiques	CLIP (encodeur visuel)	Vecteur de 512 dimensions utilisé pour l'appariement objet-à-objet
Génération d'image	DALL-E 2 (modèle de diffusion, OpenAI, via API)	Générer des images de scènes réarrangées de façon humaine, à partir du texte (+ inpainting)
Appariement	Similarité cosinus CLIP + algorithme hongrois	Associer les objets réels aux objets générés
Estimation de pose	ICP sur les masques + ResNet (ImageNet-21k) pour lever les ambiguïtés de symétrie	Calculer la transformation 2D entre pose initiale et pos cible
Exécution robotique	Primitives de saisie « faites main » + planification IK, bras Franka Emika Panda, ventouse	Déplacer physiquement chaque objet vers sa pose cibl

3. Ce qui peut être fait différemment aujourd'hui, brique par brique

L'écosystème des modèles de fondation a énormément évolué depuis fin 2022. Pour chaque brique du pipeline, un ou plusieurs modèles plus récents, plus performants et souvent plus simples à déployer (parfois en un seul modèle unifié) sont aujourd'hui disponibles. Le tableau ci-dessous synthétise ces remplacements possibles ; les sous-sections qui suivent détaillent les plus importants.

3.1 Tableau de synthèse des remplacements possibles

Brique d'origine (2022)	Limite constatée	Alternatives récentes (2024-2026)
Mask R-CNN (détection fermée à 1200 classes LVIS)	Classes prédites souvent incorrectes ; vocabulaire fermé	Grounding DINO + SAM 2 / SAM 3 (« Grounded-SAM » détection et segmentation à vocabulaire ouvert par simple texte ; ou Florence-2 (Microsoft), modèle unifié détection + segmentation + légendage en un seul appe
OFA (captioning)	Modèle spécialisé, assez rigide	Modèles vision-langage généralistes : GPT-4o / GPT-4V Qwen2-VL, LLaVA-OneVision, Gemini — légendes plus riches et instructibles par prompt

Brique d'origine (2022)	Limite constatée	Alternatives récentes (2024-2026)
Flair NLP (POS tagging) pour extraire les noms	Étape purement linguistique, déconnectée du contexte visuel	Un grand modèle de langage (GPT-4o, Llama 3/4) peut directement produire un prompt de scène complet et cohérent à partir des légendes, sans étape d'étiquetag séparée
CLIP (features + appariement)	Résolution et alignement sémantique limités	SigLIP / SigLIP 2, DINOv2 : embeddings visuels plus discriminants et plus robustes pour l'appariement inte domaine (image réelle ↔ image générée)
DALL-E 2 (diffusion, faible résolution, contrôle limité)	Artefacts, faible fidélité aux contraintes spatiales, prompts uniquement textuels	FLUX.1 (Black Forest Labs), Stable Diffusion 3.5, DALL-E / GPT-image-1, Imagen 3/4 : bien meilleure adhérence au prompt, résolution, cohérence géométrique et gestion de l'inpainting
Filtrage « sample-and-filter » manuel	Heuristique de rejet basique (comptage d'objets, chevauchements)	Un VLM (GPT-4o, Qwen2-VL) peut juger directement la plausibilité et la qualité de chaque image générée en langage naturel, remplaçant les règles codées à la mai
ICP + ResNet pour la pose 2D/3D	Limité à 3 degrés de liberté (x, y, θ), suppose une vue du dessus	Modèles de pose 6D appris de bout en bout (ex. FoundationPose) permettant un réarrangement compl en 6-DoF, au-delà du plan de table
Primitives de saisie codées à la main + IK	Spécifique au robot, nécessite un ingénieur pour chaque nouvelle géométrie d'objet	Modèles Vision-Language-Action (VLA) génériques : OpenVLA, π0 / π0.5 (Physical Intelligence), RT-2, GR00 N1 (NVIDIA), Octo — la saisie et le placement sont app et généralisent à de nouveaux objets/robots sans primitives manuelles

3.2 Perception : de Mask R-CNN vers la détection/segmentation à vocabulaire ouvert

La limite la plus citée par les auteurs eux-mêmes est que les classes prédites par Mask R-CNN sont souvent fausses, ce qui les a obligés à ajouter un modèle de légendage séparé (OFA) juste pour obtenir un nom fiable. Cette faiblesse est aujourd'hui largement résolue : Grounding DINO (détection à vocabulaire ouvert par description textuelle libre) combiné à Segment Anything (SAM, puis SAM 2 pour la vidéo, puis SAM 3 « Segment Anything with Concepts », sorti fin 2025) forme le duo « Grounded-SAM », qui détecte et segmente n'importe quel objet décrit en langage naturel, sans être limité aux 1200 classes de LVIS. Florence-2 (Microsoft, 2024) va plus loin en unifiant détection, segmentation, légendage et OCR dans un unique modèle séquence-à-séquence, ce qui simplifierait grandement cette partie du pipeline.

3.3 Description et prompt : des VLM généralistes au lieu d'un pipeline en plusieurs étapes

Le pipeline original enchaîne trois modèles indépendants (Mask R-CNN → OFA → Flair NLP) uniquement pour obtenir un prompt textuel correct. Un modèle vision-langage généraliste moderne (GPT-4o, Qwen2-VL, LLaVA-OneVision) peut réaliser cette chaîne en une seule requête : recevoir l'image de la scène et renvoyer directement une description structurée des objets, voire un prompt déjà prêt pour le modèle de génération d'image. Cela réduit le nombre de modèles à maintenir et améliore la robustesse, au prix d'une dépendance à une API externe (coût, latence, confidentialité) si un modèle propriétaire est utilisé.

3.4 Génération d'image : de DALL-E 2 aux modèles de diffusion/flux les plus récents

DALL-E 2 reste un modèle de diffusion latent relativement ancien (2022). Depuis, plusieurs familles de modèles de génération d'image ont nettement amélioré la fidélité au prompt, la cohérence géométrique et la résolution : FLUX.1 (Black Forest Labs, 2024, avec des poids ouverts pour la variante « schnell »), Stable Diffusion 3.5 (Stability AI, modèle ouvert et personnalisable), DALL-E 3 puis GPT-image-1 côté OpenAI, et Imagen 3/4 côté Google. Pour l'usage visé ici (générer un agencement plausible d'objets du quotidien, avec inpainting pour respecter les objets fixes), un modèle offrant un bon contrôle par masque et une bonne compréhension des relations spatiales (« à côté de », « empilé sur ») serait particulièrement pertinent — un point que les auteurs de DALL-E-Bot signalaient déjà comme une limite de leur époque.

3.5 Exécution robotique : des primitives de saisie manuelles aux modèles Vision-Language-Action

La partie la moins « modèle de fondation » du pipeline original est justement l'exécution physique : les primitives de saisie sont codées à la main et la planification se limite à de l'IK et du pick-and-place top-down en 3-DoF. C'est précisément la brique qui a le plus progressé depuis 2023 grâce aux modèles Vision-Language-Action (VLA), qui prennent en entrée une image et une instruction en langage naturel et produisent directement une séquence d'actions du robot, en généralisant à de nouveaux objets et parfois à de nouveaux robots. Les principaux représentants : RT-2 (Google DeepMind, 2023), OpenVLA (modèle ouvert de 7 milliards de paramètres entraîné sur près d'un million d'épisodes du jeu de données Open X-Embodiment), π0 puis π0.5 (Physical Intelligence, architecture « flow matching » sur un VLM pré-entraîné, generalisation dite « open-world »), et GR00T N1 / N1.5 (NVIDIA, orienté robots humanoïdes). Remplacer les primitives manuelles de DALL-E-Bot par un tel modèle permettrait de dépasser le pick-and-place top-down rigide et d'aborder des manipulations 6-DoF plus complexes (empilement, insertion, objets non rigides).

4. Au-delà du remplacement brique par brique : des architectures entières plus récentes

Remplacer chaque modèle isolément est une chose ; il est au moins aussi intéressant de regarder comment le pipeline lui-même a été repensé par la suite, y compris par les auteurs originaux. C'est probablement l'angle le plus valorisable pour un projet universitaire : montrer que vous avez identifié non seulement de meilleurs modèles, mais une meilleure architecture.

4.1 Dream2Real (2023) — la suite directe de DALL-E-Bot, par la même équipe

Les mêmes auteurs (Kapelyukh, Ren, Alzugaray, Johns, Imperial College London) ont publié quelques mois plus tard Dream2Real (arXiv:2312.04533, ICRA 2024), qui change la logique centrale du pipeline. Au lieu de demander à un modèle de diffusion de générer une image 2D d'un agencement plausible, le robot construit une représentation 3D de la scène (de type NeRF), y effectue virtuellement de nombreux réarrangements possibles des objets, en rend chaque configuration sous forme d'image, puis fait évaluer ces rendus par un modèle vision-langage (VLM) au regard de l'instruction utilisateur donnée en langage naturel. La configuration la plus plausible est enfin recréée par pick-and-place.

Cette approche a deux avantages majeurs par rapport à DALL-E-Bot : elle est conditionnée par le langage (l'utilisateur peut donner une instruction précise, par exemple « mets la tasse à droite du clavier », plutôt que de subir un agencement générique « humain »), et elle fonctionne nativement en 6 degrés de liberté plutôt qu'en 3-DoF top-down. En contrepartie, elle nécessite de construire une représentation 3D de la scène (plus coûteux qu'une simple photo) et dépend de la qualité du VLM évaluateur plutôt que d'un modèle de diffusion pour « imaginer ».

4.2 Autres travaux de suivi pertinents à citer

- Stimulating Imagination / « Something Something Placement » (2024) : décompose la tâche en localisation d'objet + imagination du but + contrôle, avec un modèle de diffusion conditionné par le langage pour imaginer des poses 3D directement, plutôt que de passer par une image 2D intermédiaire.
- SG-Bot (arXiv:2309.12188, 2023) : remplace l'image générée par un graphe de scène (scene graph) et un modèle de type Graph-to-3D, ce qui garantit une meilleure cohérence géométrique entre la scène initiale et la scène imaginée.
- PACA (arXiv:2410.22059, 2024) : ajoute une attention consciente de la perspective pour un réarrangement zero-shot plus robuste aux angles de vue variés.
- RoboPoint (arXiv:2406.10721, 2024) et SpatialVLM (CVPR 2024) : des VLM spécialisés dans la prédiction de points d'affordance et le raisonnement spatial métrique (distances, tailles), utiles pour fiabiliser l'étape de pose sans passer par de l'ICP classique.
- DegustaBot (arXiv:2407.08876, 2024) : va plus loin en estimant des préférences visuelles personnalisées (au-delà d'un simple agencement « générique »), en s'appuyant uniquement sur des modèles pré-entraînés, zero-shot.

4.3 Schéma d'architecture modernisée recommandée

En combinant les éléments ci-dessus, une version « 2026 » plausible du pipeline pourrait ressembler à ceci, et constitue une proposition raisonnable à présenter comme votre contribution de groupe :

- Perception : Grounding DINO + SAM 2/3 (ou Florence-2) pour une détection/segmentation à vocabulaire ouvert.
- Compréhension de scène et prompt : un VLM généraliste (GPT-4o / Qwen2-VL / modèle ouvert équivalent) décrit la scène et peut recevoir une instruction utilisateur en langage naturel (dépassant l'agencement « générique » de DALL-E-Bot).
- Imagination du but : soit génération d'image avec FLUX.1 / SD3.5 / GPT-image-1 (fidèle à l'esprit DALL-E-Bot), soit — approche plus robuste — rendu de configurations 3D évaluées par VLM à la Dream2Real.
- Appariement et pose : SigLIP2/DINOv2 pour l'appariement sémantique, complété par un modèle de pose 6D appris (type FoundationPose) plutôt que l'ICP 2D d'origine.
- Exécution : un modèle Vision-Language-Action (π0.5, OpenVLA, GR00T N1) pour la saisie et le placement, en remplacement des primitives codées à la main, avec un vrai raisonnement 6-DoF.

5. Pistes de détournement et autres cas d'usage possibles

Le sujet vise explicitement l'ameublement d'un bureau ou la mise en place d'une table. Le même pipeline (« décrire → imaginer → reproduire »), étant générique et zero-shot par construction, se prête cependant à de nombreux autres usages, qu'il peut être intéressant de mentionner dans la conclusion de votre projet comme perspectives ou comme démonstrations complémentaires :

- Rangement domestique généraliste : ranger une étagère, un tiroir de cuisine, une bibliothèque (par exemple par couleur, taille ou genre), au-delà du seul bureau ou de la seule table.
- Logistique et kitting industriel : préparation de kits de pièces sur une station de travail, réapprovisionnement de rayons en grande distribution, tri de colis en entrepôt selon un agencement optimal.
- Mise en scène pour la photographie ou l'immobilier : générer et recréer physiquement un agencement « désirable » d'objets ou de meubles pour une prise de vue (home staging), ou pré-visualiser un réagencement avant de le réaliser.
- Restauration et événementiel : dressage de table automatisé à grande échelle (couverts, verres), reproduction cohérente d'un mets ou d'un dressage standardisé sur plusieurs tables.
- Assistance aux personnes en perte d'autonomie ou en situation de handicap : réarranger un plateau, une table de chevet ou un poste de travail selon des préférences personnelles apprises au fil du temps (dans l'esprit de DegustaBot), pour limiter l'effort physique de l'utilisateur.
- Merchandising et vitrines commerciales : réagencement automatique et périodique d'une vitrine ou d'un présentoir pour suivre des tendances visuelles, en s'appuyant sur les mêmes modèles de diffusion « esthétiques ».
- Environnements médicaux ou de laboratoire : disposition standardisée d'instruments sur un plateau opératoire ou un poste de manipulation, avec un objectif de reproductibilité plutôt que d'esthétique.
- Génération de données d'entraînement : utiliser le module de génération d'image/3D pour produire automatiquement des scènes d'entraînement variées et réalistes (augmentation de données) pour d'autres tâches de manipulation robotique.
- Détournement à surveiller (limite éthique) : la même capacité à « imaginer puis reproduire une scène plausible » pourrait en théorie servir à recréer des scènes trompeuses (mise en scène falsifiée d'un lieu, dissimulation d'objets). Ce point mérite d'être mentionné dans un projet universitaire comme limite et question de responsabilité, sans qu'il s'agisse d'un cas d'usage à développer.

6. Conclusion

DALL-E-Bot a démontré, dès 2022, qu'un modèle de diffusion entraîné à l'échelle du Web pouvait servir de « moteur d'imagination » pour un robot, sans aucune donnée d'entraînement spécifique à la tâche. Trois ans plus tard, chacune des briques de son pipeline dispose d'une alternative nettement plus performante — segmentation à vocabulaire ouvert, VLM généralistes, générateurs d'image de nouvelle génération, et surtout modèles Vision-Language-Action pour l'exécution. Plus important encore, les auteurs eux-mêmes ont fait évoluer l'architecture globale avec Dream2Real, en remplaçant la génération d'image 2D par un raisonnement 3D évalué par un VLM et conditionné par le langage. Un projet de groupe gagnera à présenter ces deux niveaux de mise à jour : le remplacement des modèles brique par brique, et la proposition d'une architecture repensée s'inspirant de Dream2Real et des travaux de suivi (SG-Bot, PACA, RoboPoint).

Références principales

Kapelyukh, Vosylius, Johns, « DALL-E-Bot: Introducing Web-Scale Diffusion Models to Robotics », IEEE RA-L, 2023 — arxiv.org/abs/2210.02438

Kapelyukh, Ren, Alzugaray, Johns, « Dream2Real: Zero-Shot 3D Object Rearrangement with Vision-Language Models », ICRA 2024 — arxiv.org/abs/2312.04533

Zhai et al., « SG-Bot: Object Rearrangement via Coarse-to-Fine Robotic Imagination on Scene Graphs », 2023 — arxiv.org/abs/2309.12188

« Stimulating Imagination: Towards General-purpose Object Rearrangement », 2024 — arxiv.org/abs/2408.01655

« PACA: Perspective-Aware Cross-Attention Representation for Zero-Shot Scene Rearrangement », 2024 — arxiv.org/abs/2410.22059

Yuan et al., « RoboPoint: A Vision-Language Model for Spatial Affordance Prediction for Robotics », 2024 — arxiv.org/abs/2406.10721

Chen et al., « SpatialVLM: Endowing Vision-Language Models with Spatial Reasoning Capabilities », CVPR 2024

Kim et al., « OpenVLA: An Open-Source Vision-Language-Action Model », 2024 — arxiv.org/abs/2406.09246

Black et al. (Physical Intelligence), « π0: A Vision-Language-Action Flow Model for General Robot Control », 2024, et « π0.5 », 2025 — arxiv.org/abs/2410.24164

Bjorck et al. (NVIDIA), « GR00T N1: An Open Foundation Model for Generalist Humanoid Robots », 2025 — arxiv.org/abs/2503.14734

Liu et al., « Grounding DINO: Marrying DINO with Grounded Pre-training for Open-Set Object Detection », ECCV 2024

Ravi et al. (Meta), « SAM 2: Segment Anything in Images and Videos », 2024, et « SAM 3 », 2025

Xiao et al. (Microsoft), « Florence-2 », CVPR 2024