Vers un pipeline 100% gratuit et modernisé

Projet VA50 — au-delà de DALL-E-Bot (2022) et de ses successeurs

Encadrant : Nathan Crombez

Base de départ : DALL-E-Bot (arXiv:2210.02438) — voir aussi Dream2Real, SG-Bot, PACA

Ce document complète le premier rapport. Il ne revient pas sur toutes les références déjà citées, mais se concentre sur deux choses : (1) une chaîne complète, concrète et 100% gratuite, brique par brique, qui va plus loin que DALL-E-Bot (2022) et que les travaux intermédiaires (Dream2Real, SG-Bot, PACA...) déjà vus ; (2) une explication simple, sans jargon, de ce que chaque nouveauté apporte réellement. Chaque brique est réexpliquée dans son rôle d'origine avant de présenter ce qui change.

1. Rappel : à quoi sert chaque brique, avant de parler de nouveauté

Avant de moderniser, il faut se souvenir de ce que chaque brique fait dans la chaîne, indépendamment du modèle utilisé. C'est le rôle qui compte, pas le nom du modèle.

Brique	Rôle (à quoi ça sert)
Perception / segmentation	Trouver où sont les objets dans l'image et découper chacun proprement (un masque par objet).
Description (captioning)	Donner un nom fiable à chaque objet détecté, pour pouvoir en parler avec des mots.
Construction du prompt / de la consigne	Résumer la scène en une phrase ou une instruction exploitable par la suite de la chaîne.
Génération / imagination du but	Proposer à quoi devrait ressembler la scène une fois rangée, de façon plausible et naturelle.
Appariement	Relier chaque objet réel à sa version « imaginée », pour savoir qui va où.
Estimation de la pose	Calculer de combien et dans quel sens il faut déplacer chaque objet pour l'amener à sa position cible.
Exécution robotique	Réaliser physiquement les déplacements (saisir, orienter, poser) sans abîmer les objets ni se tromper.

2. Les modèles gratuits et disponibles aujourd'hui, brique par brique

Tous les modèles ci-dessous ont du code et des poids publics (GitHub / HuggingFace), utilisables sans payer d'API. C'est la base de la chaîne proposée en partie 3.

Brique	Modèle(s) gratuit(s) recommandé(s)	Pourquoi celui-ci
Perception / segmentation	Grounding DINO + SAM 2 (ou SAM 3)	Détecte et découpe n'importe quel objet décrit en texte libre, sans liste fermée de classes.
Description + prompt	Qwen2-VL ou LLaVA-OneVision	Un seul modèle voit l'image et écrit une description utilisable directement, sans étapes séparées.
Reconstruction 3D de la scène	3D Gaussian Splatting (implémentations open-source)	Construit une maquette 3D de la table à partir de quelques photos, bien plus rapide qu'un NeRF classique.

Brique	Modèle(s) gratuit(s) recommandé(s)	Pourquoi celui-ci
Génération d'idées d'agencement	FLUX.1 [schnell] ou Stable Diffusion 3.5	Propose plusieurs images d'agencements plausibles, à partir du texte, gratuitement et en local.
Jugement / sélection du meilleur agencement	Qwen2-VL (en mode évaluateur)	Compare les propositions à l'instruction donnée et choisit la plus cohérente, comme un relecteur.
Appariement objets réels ↔ imaginés	DINOv2 (ou SigLIP 2)	Vecteurs visuels plus fiables que CLIP pour reconnaître le « même » objet sous un autre angle ou style.
Pose / alignement	FoundationPose	Calcule directement une pose 3D complète (6 degrés de liberté), pas seulement x, y et une rotation à plat.
Exécution robotique	OpenVLA ou pi0 / pi0.5 (Physical Intelligence)	Politique apprise qui relie image + instruction à un mouvement du bras, sans coder de primitives à la main.

3. La chaîne complète proposée : aller plus loin que 2022... et que 2023-2024

L'idée n'est pas seulement de remplacer chaque brique par un modèle plus récent, mais de changer la logique à deux endroits précis, là où même Dream2Real, SG-Bot et PACA s'arrêtent : (a) combiner génération d'image ET jugement par un second modèle, plutôt que de choisir l'un ou l'autre ; (b) fermer la boucle après l'exécution, avec une vérification automatique du résultat, alors que tous ces travaux s'arrêtent une fois le geste physique exécuté.

Étape 1 — Voir et nommer la scène

Grounding DINO + SAM 2 détectent et découpent chaque objet sur la table. Qwen2-VL décrit directement la scène et produit une phrase de contexte, en une seule passe (fini la chaîne Mask R-CNN → OFA → étiquetage grammatical de 2022, qui faisait intervenir trois modèles indépendants pour un résultat moins fiable).

En clair : *c'est comme remplacer trois personnes qui se passent l'information à la chaîne (et qui déforment un peu le message à chaque fois) par une seule personne qui regarde la photo et écrit directement la bonne description.*

Étape 2 — Construire une maquette 3D de la scène

Plutôt que de travailler sur une seule photo à plat (comme DALL-E-Bot en 2022), le robot prend quelques images sous différents angles et reconstruit une maquette 3D complète de la table avec le 3D Gaussian Splatting, une technique plus récente et beaucoup plus rapide que le NeRF utilisé par Dream2Real fin 2023.

En clair : *au lieu d'une photo d'identité de la scène, le robot se fait un vrai plan en volume, qu'il peut tourner dans tous les sens virtuellement avant de toucher le moindre objet.*

Étape 3 — Imaginer PLUSIEURS agencements possibles

FLUX.1 (ou Stable Diffusion 3.5) génère plusieurs propositions d'agencement à partir du texte, exactement dans l'esprit de DALL-E-Bot mais avec un modèle bien plus fidèle aux contraintes spatiales. Chaque proposition est ensuite testée virtuellement sur la maquette 3D (comme Dream2Real), ce qui donne plusieurs scènes 3D candidates plutôt qu'une seule image 2D figée.

Étape 4 — Faire juger les propositions par un second modèle

C'est le premier vrai pas au-delà de l'existant : au lieu de choisir entre « générer une image » (DALL-E-Bot) ou « faire évaluer des configurations par un VLM » (Dream2Real), on fait les deux à la suite. Qwen2-VL reçoit les rendus des différentes scènes 3D candidates et l'instruction de l'utilisateur, et désigne la meilleure — un peu comme un architecte qui dessine plusieurs plans, puis un client qui choisit celui à réaliser.

En clair : *un premier modèle propose des idées (il est créatif mais parfois imprécis), un second modèle vérifie qu'elles respectent bien la consigne (il est plus rigoureux mais moins imaginatif). Combiner les deux corrige les défauts de chacun.*

Étape 5 — Associer et positionner les objets, en 3D

DINOv2 associe chaque objet réel à sa version dans la scène choisie. FoundationPose calcule directement une pose 3D complète (position et orientation dans les trois axes), là où DALL-E-Bot se limitait à une rotation à plat sur une image 2D.

Étape 6 — Exécuter avec un modèle Vision-Language-Action, en boucle fermée

OpenVLA ou pi0 / pi0.5 reçoivent en continu l'image de la caméra et l'objectif à atteindre, et pilotent le bras directement, sans primitives de saisie codées à la main. Contrairement au pipeline de 2022, qui exécutait un plan calculé une fois pour toutes (« en boucle ouverte »), ces modèles regardent la caméra à chaque instant

et corrigent leur geste en temps réel s'il y a un écart.

> ***En clair :*** *c'est la différence entre suivre une recette de cuisine les yeux fermés, et cuisiner en goûtant et ajustant au fur et à mesure.*

Étape 7 — Vérifier le résultat tout seul (la vraie nouveauté de ce projet)

Une fois le réarrangement terminé, le robot reprend une photo et redemande à Qwen2-VL : « Est-ce que cette scène correspond bien à ce qui était demandé ? ». Si la réponse est non, la chaîne reprend automatiquement à l'étape 3 pour affiner l'agencement, sans qu'un humain n'ait besoin d'intervenir pour valider ou corriger. Aucun des travaux cités dans le premier rapport (DALL-E-Bot, Dream2Real, SG-Bot, PACA) ne referme cette boucle : ils s'arrêtent tous après l'exécution, en supposant que le résultat est correct.

4. Ouverture : et si la brique la plus intéressante servait à ranger une bibliothèque ?

Le premier rapport citait le rangement d'étagères parmi les autres usages possibles. C'est une très bonne piste à creuser, car elle change la nature même de la brique la plus visible du pipeline — la partie « imagination du but » — d'un problème esthétique à un problème logique, ce qui est en réalité plus simple et plus fiable à réaliser.

Ce qui change par rapport à une table à dresser

Dresser une table (DALL-E-Bot) répond à une question de goût : « qu'est-ce qu'un agencement humain et naturel ? ». Ranger une bibliothèque répond à une question de règle : « alphabétique par auteur ? par genre ? par couleur de tranche ? par taille décroissante ? ». Cette différence a une conséquence directe et très intéressante sur l'architecture.

Étape « imagination » devenue un simple tri, pas une génération d'image

Quand le critère de rangement est une règle logique plutôt qu'une question d'esthétique, il devient inutile de demander à un modèle de diffusion d'imaginer une photo de l'étagère rangée : ce serait un détour coûteux et peu fiable pour un problème qui est en réalité un simple tri. Un grand modèle de langage (le même Qwen2-VL, ou un LLM texte seul) peut directement lire les titres et noms d'auteurs détectés sur les tranches, puis renvoyer l'ordre final sous forme de liste — bien plus rapide et bien plus fiable qu'une image générée.

> ***En clair :*** *pour dresser une table, il faut un peu de goût artistique, donc un modèle « créatif » comme FLUX.1 est utile. Pour ranger par ordre alphabétique, il faut juste savoir compter et trier, donc un LLM classique suffit et va plus vite.*

Ce que ça change pour la perception

Il faut ajouter une capacité de lecture de texte sur l'image (OCR), pour lire le titre et l'auteur inscrits sur la tranche de chaque livre — Qwen2-VL et Florence-2 savent déjà faire cela nativement, sans modèle supplémentaire. C'est une bonne illustration de l'intérêt des VLM généralistes modernes : la même brique « perception » sert aussi bien à décrire une fourchette qu'à lire un titre de livre.

Ce que ça change pour l'exécution — le vrai argument en faveur des VLA

Un livre ne se saisit pas comme une fourchette : c'est un objet plat, fin, qui doit être incliné pour être sorti d'un rayonnage serré, puis reposé debout. Les primitives de saisie codées à la main de DALL-E-Bot (pensées pour une ventouse et des objets de cuisine) ne fonctionneraient pas du tout ici sans être entièrement réécrites. C'est exactement ce que les modèles Vision-Language-Action comme OpenVLA ou pi0 apportent : une politique de saisie apprise sur une grande variété d'objets et de gestes, qui généralise à un livre sans qu'il faille reprogrammer une nouvelle primitive à la main.

Un vrai plus : la personnalisation dans le temps

Comme évoqué pour DegustaBot dans le premier rapport, la bibliothèque est un bon cas pour ajouter une mémoire des préférences : le robot pourrait apprendre au fil des rangements qu'un utilisateur préfère ses livres triés par couleur plutôt que par auteur, sans qu'on ait besoin de le repréciser à chaque fois.

---

5. Conclusion

La chaîne proposée ici (Grounding DINO + SAM 2 → Qwen2-VL → 3D Gaussian Splatting → FLUX.1 → jugement par VLM → DINOv2 + FoundationPose → OpenVLA/pi0 → vérification automatique) est entièrement composée de modèles gratuits et déjà disponibles sur GitHub/HuggingFace. Elle va plus loin que DALL-E-Bot en combinant génération et jugement plutôt que de choisir l'un ou l'autre, en passant en 3D plutôt qu'en 2D, et surtout en refermant la boucle par une vérification automatique du résultat — un point

qu'aucun des travaux étudiés jusqu'ici ne traite. L'exemple de la bibliothèque montre enfin que la même architecture s'adapte à un problème de nature différente (logique plutôt qu'esthétique) simplement en changeant ce qu'on demande à l'étape d'imagination, ce qui est une bonne preuve de la généralité de l'approche.